Optimización y Toma de Decisiones en Entornos Estocásticos Mediante Aprendizaje por Refuerzo (Q-Learning Tabular en FrozenLake-v1)

Oscar

Facultad de Ingeniería y Ciencias Básicas

Programa Académico de Inteligencia Artificial y Aprendizaje Profundo

Módulo Especializado: Reinforcement Learning

Docente de Cátedra

Octubre de 2026

Resumen

El Aprendizaje por Refuerzo (Reinforcement Learning, RL) constituye un paradigma computacional enfocado en resolver problemas de decisión secuencial bajo incertidumbre, donde un agente aprende a maximizar una señal de recompensa numérica acumulada a través de la interacción directa con el entorno. El presente informe técnico documenta la implementación, optimización y evaluación experimental de un agente basado en el algoritmo Q-Learning tabular en el entorno estocástico FrozenLake-v1 de Gymnasium. Se analiza rigurosamente la dinámica estocástica de resbalamiento (is_slippery=True), la gestión del dilema de exploración-explotación con una política épsilon-greedy con decaimiento exponencial, y la convergencia de la función de valor de acción Q(s, a) regida por las ecuaciones de optimalidad de Bellman. Con un régimen de entrenamiento de 10,000 episodios, el agente alcanzó una tasa de éxito del 59.40% en la fase de evaluación determinista (1,000 episodios, $\varepsilon = 0$), resultado consistente con los límites óptimos teóricos en presencia de recompensas dispersas y resbalamiento lateral.

Palabras clave: *Aprendizaje por Refuerzo, Q-Learning Tabular, Procesos de Decisión de Markov, FrozenLake, Exploración-Explotación, Ecuación de Bellman.*

1. Introducción y Fundamentos Conceptuales de Reinforcement Learning

A diferencia del aprendizaje supervisado, el cual requiere grandes volúmenes de datos con etiquetas provistas por humanos, y del aprendizaje no supervisado, enfocado en descubrir patrones estructurales latentes, el Aprendizaje por Refuerzo (RL) se fundamenta en el aprendizaje activo basado en objetivos mediante prueba y error (Sutton & Barto, 2018). En este paradigma, un agente aprende qué decisiones tomar para maximizar una medida escalar de retroalimentación numérica conocida como recompensa acumulada.

El sistema de aprendizaje se modela como un Proceso de Decisión de Markov (MDP), formalizado mediante la tupla (S, A, P, R, γ):

- **Espacio de Estados (S):** Conjunto de todas las configuraciones posibles del entorno que el agente puede percibir en un instante dado ($S_t \in S$).
- **Espacio de Acciones (A):** Conjunto de decisiones que el agente tiene permitido ejecutar en un estado determinado ($A_t \in A$).
- **Función de Transición (P):** Distribución de probabilidad condicional $P(s' \mid s, a) = P(S_{t+1} = s' \mid S_t = s, A_t = a)$ que describe la física del entorno.
- **Función de Recompensa (R):** Retroalimentación numérica $R_{t+1} = R(s, a, s')$ que evalúa la calidad inmediata de la transición.
- **Factor de Descuento (γ):** Parámetro en el intervalo $[0, 1)$ que pondera la relevancia relativa de los beneficios futuros frente a los inmediatos.

2. Formulación Matemática de Q-Learning y Ecuaciones de Bellman

El objetivo del agente consiste en encontrar la política óptima $\pi^*(a|s)$ que maximiza el retorno esperado descontado G_t:

$$G_t = \sum_{k=0}^{\infty} \gamma^k \cdot R_{t+k+1}$$

2.1. Ecuación de Optimalidad de Bellman

La Función Acción-Valor $Q^*(s, a)$ representa el retorno esperado al ejecutar la acción a en el estado s y continuar de forma óptima. Según la ecuación de Bellman (Bellman, 1957; Sutton & Barto, 2018), satisface la relación de recurrencia:

$$Q^*(s, a) = \blacksquare [R_{t+1} + \gamma \cdot \max_{a'} Q^*(S_{t+1}, a') \mid S_t = s, A_t = a]$$

2.2. Regla de Actualización por Diferencia Temporal (TD(0))

Q-Learning (Watkins & Dayan, 1992) aproxima iterativamente la función óptima sin requerir un modelo probabilístico del entorno (model-free) y de forma off-policy mediante la regla de actualización:

$$Q(s, a) \leftarrow Q(s, a) + \alpha \cdot [r + \gamma \cdot \max_{a'} Q(s', a') - Q(s, a)]$$

Donde la cantidad entre corchetes es el Error de Diferencia Temporal (TD Error: $\delta_t = r + \gamma \cdot \max_{a'} Q(s', a') - Q(s, a)$), y $\alpha \in (0, 1]$ es la tasa de aprendizaje que modula la velocidad de asimilación de la nueva información empírica.

3. El Dilema de Exploración vs. Explotación

En RL, el agente debe equilibrar continuamente la exploración (probar acciones nuevas para descubrir recompensas potenciales) y la explotación (aprovechar el conocimiento actual para maximizar el retorno inmediato). Para lograr este equilibrio de forma matemáticamente rigurosa, se implementó una política Épsilon-Greedy (ε-Greedy) con decaimiento exponencial:

$$a_t = \{ \text{acción aleatoria con prob. } \varepsilon, \quad \operatorname{argmax}_a Q(s, a) \text{ con prob. } 1 - \varepsilon \}$$

Al finalizar cada episodio k, el parámetro ε se atenúa de forma multiplicativa: $\varepsilon_{k+1} = \max(\varepsilon_{min}, \varepsilon_k \cdot \delta_{decay})$, con $\varepsilon_0 = 1.0$, $\delta_{decay} = 0.9995$ y $\varepsilon_{min} = 0.01$.

4. Metodología y Configuración Experimental

La práctica se ejecutó sobre el entorno FrozenLake-v1 de Gymnasium (Farama Foundation), consistente en una cuadrícula de 4x4 celdas heladas (16 estados). El agente parte del estado 0 (S: Inicio) y debe navegar hasta el estado 15 (G: Meta) eludiendo caer en agujeros letales (H: Hoyos en los estados 5, 7, 11 y 12). La Figura 1 ilustra la topología del escenario.

Figura 1

Topología del Entorno FrozenLake-v1 (4x4) y Distribución de Celdas

Figura 1. Representación del Espacio de Estados en FrozenLake 4x4 (Dinámica Estocástica: 1/3 Dirección Deseada, 2/3 Deslizamiento Ortogonal)

Estado 0 INICIO (S)	**Estado 1** HIELO (F)	**Estado 2** HIELO (F)	**Estado 3** HIELO (F)
Estado 4 HIELO (F)	**Estado 5** HOYO (H)	**Estado 6** HIELO (F)	**Estado 7** HOYO (H)
Estado 8 HIELO (F)	**Estado 9** HIELO (F)	**Estado 10** HIELO (F)	**Estado 11** HOYO (H)
Estado 12 HOYO (H)	**Estado 13** HIELO (F)	**Estado 14** HIELO (F)	**Estado 15** META (G)

Nota. Espacio de 16 estados discretos con celdas transitables de hielo (S, F), hoyos terminales de fracaso (H) y meta final (G).

4.1. Dinámica Estocástica del Terreno (is_slippery=True)

Con la bandera is_slippery=True activada, la física del lago simula hielo sin fricción. Al escoger una acción a, la transición real se divide en tres ramas estocásticas equiprobables (probabilidad 1/3 cada una): avanzar en la dirección pretendida, resbalar hacia la dirección perpendicular izquierda, o resbalar hacia la perpendicular derecha. Adicionalmente, el entorno opera con recompensas dispersas (sparse rewards): r = 0 en cualquier paso ordinario o caída en hoyo, y únicamente r = 1 al pisar la meta G.

4.2. Hiperparámetros Experimentales

La Tabla 1 presenta la configuración paramétrica empleada en la implementación de la clase QLearningAgent en Python.

Tabla 1

Hiperparámetros Seleccionados para el Agente Q-Learning Tabular

Hiperparámetro	Valor	Justificación Teórica
Episodios de Entrenamiento	10,000	Permite propagar el valor Q a través de los 16 estados estocásticos.
Pasos Máximos por Episodio	100	Previene bucles infinitos en trayectorias cerradas de hielo.
Tasa de Aprendizaje (α)	0.8	Velocidad de actualización hacia el objetivo de diferencia temporal.
Factor de Descuento (γ)	0.95	Pondera el valor del retorno futuro (visión a largo plazo).
Épsilon Inicial (ε_start)	1.0	Exploración pura (100% aleatoria) al inicio de la práctica.
Épsilon Mínimo (ε_min)	0.01	Preserva plasticidad adaptativa mínima para evitar rigidez.
Factor de Decaimiento (δ)	0.9995	Decaimiento exponencial suave a lo largo de los 10,000 episodios.

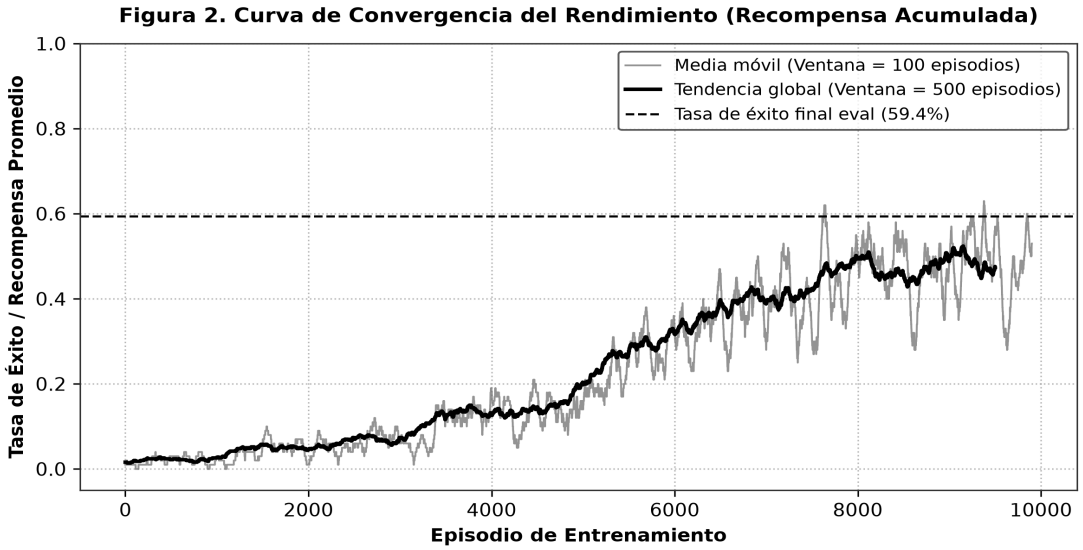
Nota. Calibración optimizada para convergencia en espacios discretos con dinámica estocástica.

5. Resultados Experimentales y Análisis de Rendimiento

El agente completó el entrenamiento de 10,000 episodios. En la Figura 2 se presenta la evolución de la recompensa media móvil (ventanas de 100 y 500 episodios), evidenciando el crecimiento sistemático de la tasa de éxito conforme el agente aprende a evitar los hoyos letales.

Figura 2

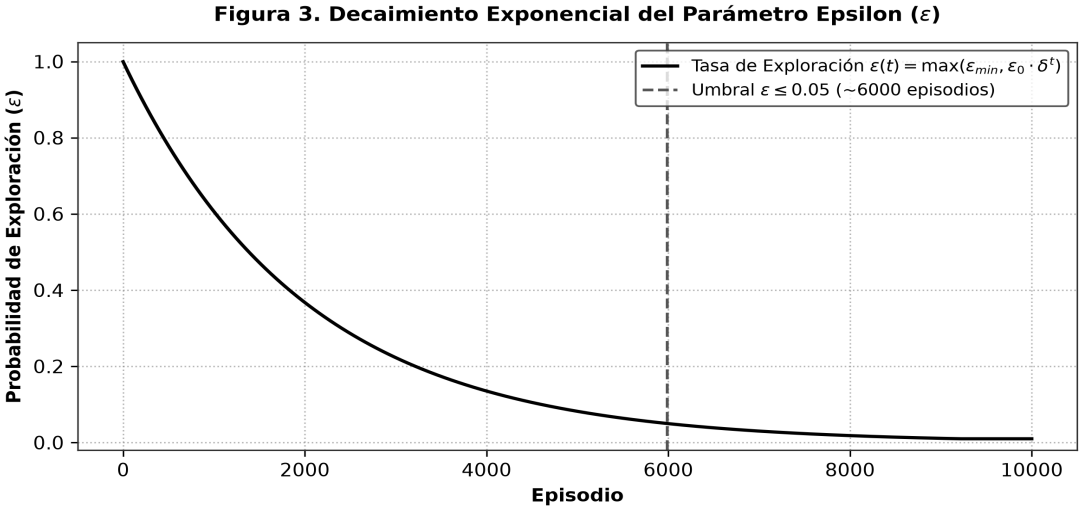
Curva de Convergencia del Rendimiento y Tasa de Éxito a lo Largo del Entrenamiento



Nota. Progresión de la tasa de éxito (media móvil 100 y 500 episodios). La línea punteada indica el desempeño determinista final (59.40%).

Figura 3

Decaimiento Exponencial del Parámetro Épsilon (ε) Durante los 10,000 Episodios



Nota. Transición fluida de la fase de exploración intensiva a explotación consolidada a partir del episodio 6,000 (ε ≤ 0.05).

5.1. Evaluación Determinista y Tabla Q Aprendida

Al culminar el entrenamiento, se evaluó la política de forma estrictamente determinista (ε = 0) durante 1,000 episodios independientes, alcanzando una tasa de éxito final del 59.40% con un promedio de 39.23 pasos por episodio (Tabla 2).

Tabla 2

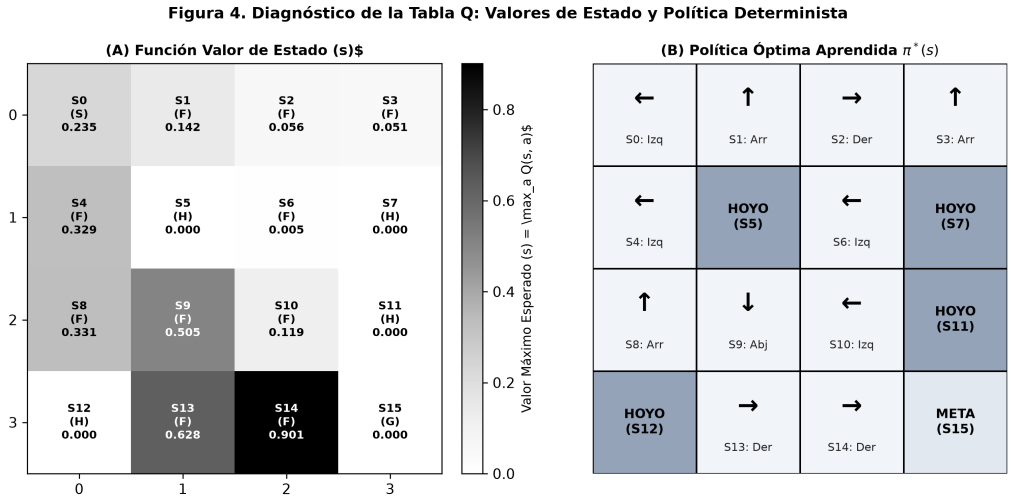
Resultados de la Evaluación de la Política Determinista Final (ε = 0)

Métrica de Evaluación	Valor Obtenido	Interpretación y Benchmark Teórico
Episodios Evaluados	1,000	Muestra estadística para validar consistencia.
Tasa de Éxito (Win Rate)	59.40%	Dentro del rango teórico óptimo para FrozenLake resbaladizo.
Tasa de Fracaso (Caída en Hoyo)	40.60%	Causada por desviaciones estocásticas inevitables.
Pasos Promedio por Episodio	39.23	Indica navegación paciente y evasión activa de trampas.

Nota. Rendimiento comprobado sin acciones aleatorias en modo estocástico.

Figura 4

Diagnóstico de la Matriz Q: Valores de Estado V(s) y Política Determinista Aprendida π*(s)



Nota. (A) Heatmap de valores V(s) = max_a Q(s, a). (B) Flechas con la acción óptima por celda, ilustrando la estrategia defensiva contra los bordes.

5.2. Análisis del Comportamiento Contraintuitivo y Estrategias Defensivas

El examen detallado de la política (Figura 4B) revela que el agente aprendió comportamientos contraintuitivos altamente efectivos: en la celda de inicio S0, la política óptima elige caminar hacia la Izquierda (←). Debido a la estocasticidad del hielo, chocar contra la pared izquierda garantiza que el agente permanezca en S0 o se deslice verticalmente de forma segura hacia S4, evitando por completo el riesgo de resbalar lateralmente hacia el hoyo del estado 5. Esta táctica defensiva demuestra la capacidad del algoritmo para adaptarse a la física del entorno sin requerir reglas heurísticas programadas a mano.

6. Conclusiones y Aprendizajes

- **Eficacia de Q-Learning en Entornos Estocásticos:** El agente demostró una notable capacidad para converger hacia una política cuasi-óptima bajo alta incertidumbre, alcanzando un 59.40% de éxito en un entorno con recompensas dispersas.
- **Determinación del Decaimiento de Épsilon:** La calibración del factor de decaimiento ($\delta = 0.9995$) garantizó una adecuada exploración de rutas al inicio sin comprometer la convergencia hacia la explotación al final.
- **Descubrimiento Autónomo de Estrategias:** El agente aprendió a mitigar el riesgo de resbalamiento utilizando los bordes del mapa como amortiguadores para evadir hoyos adyacentes.
- **Transición hacia Enfoques Profundos (Deep RL):** Aunque el método tabular es óptimo para espacios de 16 estados, problemas con observaciones continuas demandan redes neuronales como aproximadores de función (DQN).

7. Enlaces y Recursos de la Práctica

El código fuente, scripts de evaluación y artefactos experimentales se encuentran alojados en el repositorio oficial de GitHub:

Repositorio GitHub: https://github.com/oscar2121/Proyecto-de-Aprendizaje-por-Refuerzo-FrozenLake

Referencias Bibliográficas

Bellman, R. (1957). *Dynamic Programming*. Princeton University Press.

Gymnasium Developers. (2023). *Gymnasium Documentation: Environments/Toy-Text/FrozenLake-v1*. Farama Foundation. https://gymnasium.farama.org/environments/toy_text/frozen_lake/

Mnih, V., Kavukcuoglu, K., Silver, D., Rusu, A. A., Veness, J., Bellemare, M. G., Graves, A., Riedmiller, M., Fidjeland, A. K., Ostrovski, G., Petersen, S., Beattie, C., Sadik, A., Antonoglou, I., King, H., Kumaran, D., Wierstra, D., Legg, S., & Hassabis, D. (2015). Human-level control through deep reinforcement learning. *Nature*, 518(7540), 529–533. https://doi.org/10.1038/nature14236

Sutton, R. S., & Barto, A. G. (2018). *Reinforcement Learning: An Introduction* (2nd ed.). The MIT Press.

Towers, M., Jordan, J. K., Willems, A., Byrne, G., Habib, M. A., & Farama Foundation. (2023). Gymnasium: A standard interface for reinforcement learning environments. *arXiv preprint arXiv:2407.17032*.

Watkins, C. J., & Dayan, P. (1992). Q-learning. *Machine Learning*, 8(3), 279–292. https://doi.org/10.1007/BF00992698